Insight PDF Pro

Architecture RAG

LLM Mistral AI

Streamlit

Analyseur intelligent de documents PDF

Question · Résumé · Analyse · Audio · Présentation

Herman KANDOLO — Université Nationale du Vietnam (IFI)
ID: 24075122

Année académique 2025–2026

Plan

Structure de la présentation

01 Introduction & Contexte du Projet

02 Stack Technologique

03 Architecture RAG / LLM — Diagramme & Explication

04 Architecture RAG / LLM — Rôle des Composants

05 Fonctionnalités Principales

06 Pipeline d'Analyse IA — Détail Technique

07 Interface & Expérience Utilisateur

08 Système de Notation & Export

09 Comparaison Analyse Manuelle vs IA

10 Structure du Projet & Conclusion

Introduction & Contexte du Projet

Objectifs et contribution principale

Insight PDF Pro automatise l'analyse de documents PDF grâce à l'IA, offrant résumé, Q&A, analyse sémantique, lecture audio et génération de présentations PowerPoint en quelques secondes.

Importer

Charger des PDF via l'interface Streamlit

Analyser

Interroger le document en langage naturel

Synthétiser

Résumer et analyser les thèmes & mots-clés

Exporter

Audio MP3 et présentations PowerPoint

5

Onglets

∞

Pages PDF

2

Langues audio

3

Styles PPT

Stack Technologique

Bibliothèques open source — pip install -r requirements.txt

Couche	Technologie	Version	Rôle
Interface utilisateur	**Streamlit**	1.29+	Application web interactive
Intelligence artificielle	**Mistral AI**	latest	LLM pour l'analyse des documents
Extraction PDF	**PyPDF2**	3.0.1	Lecture page par page des fichiers PDF
Text-to-Speech	**gTTS**	latest	Synthèse vocale FR et EN via Google
Génération PowerPoint	**python-pptx**	latest	Création de fichiers .pptx automatiques
Analyse de texte	**re + Counter**	stdlib	Fréquences, mots-clés et statistiques
Configuration	**python-dotenv**	1.0.0	Gestion sécurisée de la clé API Mistral

Prérequis : Python 3.8+ · Clé API Mistral gratuite sur console.mistral.ai · Déployable sur Streamlit Cloud

Architecture RAG / LLM — Diagramme & Explication

Phase OFFLINE — Indexation

Collecte
PDF/DOCX/TXT

▶

Chunking
Découpage

▶

Embeddings
Vecteurs

▶

Vector DB
FAISS/Pinecone

Phase ONLINE — Inférence (contexte : Insight PDF Pro)

Question
utilisateur

▶

Retriever
Top-K chunks

▶

Documents
Pertinents

▶

Construction
du Prompt

▶

Mistral
Génération

Phase OFFLINE

Collecte → Chunking → Embeddings → Vector DB. Centralisation des connaissances.

Phase ONLINE

Requête → Retriever (cosinus) → Prompt → LLM → Réponse fiable basée sur données réelles.

Qualité chunking

Segments trop longs ou courts dégradent la précision. Adapter la taille au domaine.

Stratégie Top-K

Le LLM lit uniquement le contexte fourni dans le prompt, non la base vectorielle.

Architecture RAG / LLM — Rôle des Composants

Pipeline standardisé — évaluation équitable et reproductible

Étape	Composant	Phase	Rôle dans Insight PDF Pro	Signal
1	PDF / DOCX / TXT	Indexation	Fichiers sources uploadés via Streamlit	✓ Fort
1	Extraction du texte	Indexation	PyPDF2 page par page · python-docx paragraphes	✓ Fort
1	Chunking	Indexation	Segmentation en blocs cohérents pour la recherche sémantique	✓ Fort
1	Embeddings vectoriels	Indexation	Conversion de chaque chunk en vecteur numérique	✓ Fort
2	Retriever	Retrieval	Sélection des top-k chunks par similarité cosinus	✓ Fort
3	Construction du prompt	Augmentation	Injection PDF + question · Temp. 0.3 · 1000 tokens	✓ Fort
4	Mistral Large	Génération	Génère la réponse structurée basée sur le contexte	✓ Fort
4	Parsage JSON + fallback	Génération	Nettoyage backticks · Valeurs par défaut si JSONDecodeError	~ Modéré

Fonctionnalités Principales

5 onglets couvrant l'intégralité du cycle d'analyse

Chat Intelligent

Posez des questions en langage naturel. Mistral Large répond avec précision basée sur le contenu extrait.

Synthèse Auto.

Résumés courts, moyens ou détaillés via un slider de précision. Génération en un clic.

Analyse Lexicale

Fréquences, mots-clés, statistiques. Analyse sémantique des thèmes et du ton.

Lecture Audio

Convertissez n'importe quelle page en fichier MP3 via gTTS. Français et Anglais.

Présentation PPT

Fichier .pptx généré automatiquement par l'IA avec 3 à 15 slides et 3 styles visuels.

Pipeline d'Analyse IA — Détail Technique

Du fichier PDF à la réponse Mistral

1 Upload & Extraction

- PyPDF2 page par page
- python-docx paragraphes
- TXT décodé UTF-8

2 Chunking & Embedding

- Découpage cohérent
- Conversion en vecteurs
- Stockage recherchable

3 Construction du Prompt

- Question + contexte
- Température 0.3
- max_tokens 1000

4 Appel Mistral & Parsage

- Nettoyage backticks
- Parsage JSON sécurisé
- Valeurs fallback

Délai de 0,1 s entre requêtes — limite de débit API respectée · Barre de progression Streamlit mise à jour en temps réel

Interface & Expérience Utilisateur (UX)

Design inspiré de l'esthétique Gemini / Google

Choix de Design

- Dégradé corail → violet → rose (esthétique Gemini)
- Police Google Sans — hiérarchie typographique soignée
- Animations CSS : fadeIn et hover translateY
- Mise en page wide — colonnes responsives Streamlit
- Boutons arrondis (border-radius 20px) style Gemini
- Sidebar épurée avec statut du document chargé

Flux Utilisateur — 4 Étapes

1. **Charger un PDF**
   Sidebar → Upload → extraction automatique
2. **Choisir l'onglet**
   Chat, Synthèse, Analyse, Audio ou PPT
3. **Lancer l'analyse**
   Cliquer → spinner → réponse IA en direct
4. **Exploiter les résultats**
   Lire, écouter ou télécharger le .pptx

Système de Notation & Export des Résultats

Scoring Mistral et exports multi-format

< 5 s
Par page analysée

3
Formats supportés

MP3
Export audio gTTS

3 styles
Thèmes PPT

Niveaux de synthèse

Court	Résumé concis, points essentiels uniquement
Moyen	Équilibre entre détail et concision
Détaillé	Analyse approfondie de tous les thèmes

Formats d'export

Audio MP3

- Page choisie
- gTTS — FR & EN
- Lecture instantanée

PowerPoint

- 3 à 15 slides
- Structure JSON IA
- 3 thèmes visuels

```
prompt = f"Crée une structure JSON pour {n_slides} slides..."  ·  data_ppt = json.loads(json_str)  →  create_pptx(data_ppt, style)
```

Comparaison — Analyse Manuelle vs Insight PDF Pro (IA)

Même jeu de conditions pour toutes les évaluations

Critère	Analyse Manuelle	Insight PDF Pro (IA)	Avantage
Temps par page	10 – 15 min	< 5 secondes (API)	✓ IA
Objectivité	Subjective et variable	Critères constants et reproductibles	✓ IA
Résumé exportable	Manuel (copié-collé)	Résumé généré et téléchargeable	✓ IA
Lecture audio	Non disponible	MP3 automatique FR/EN	✓ IA
Présentation PPT	Création manuelle (1h+)	Généré par IA en < 30 secondes	✓ IA
Analyse sémantique	Implicite, non documentée	Thèmes et tons explicitement listés	✓ IA

⚠ Limite actuelle : la qualité de l'analyse dépend du modèle LLM. Une lecture humaine finale reste recommandée pour les décisions critiques.

Structure du Projet & Perspectives

Arborescence et évolutions futures

Arborescence des Fichiers

```
insight-pdf-pro/
    app.py
    .env
    requirements.txt
    README.md
    exports/
        audio/
        pptx/
```

Perspectives d'Évolution

Court terme

- Support ODT et RTF
- Analyse multilingue avancée
- Recherche dans le document

Moyen terme

- Comparaison entre documents
- API REST pour intégration
- Historique de sessions

Long terme

- Dashboard analytique multi-sessions
- Fine-tuning du modèle Mistral
- IA explicable (XAI / SHAP)

Conclusion Générale & Références

Module	Résultat	Technologie clé
Architecture RAG	Pipeline opérationnel avec Mistral Large	Mistral Large
Chat / Q&A	Questions en langage naturel sur le PDF	Prompt Engineering
Synthèse	Résumé court / moyen / détaillé	Mistral Large
Analyse Lexicale	Fréquences + thèmes sémantiques	PyPDF2 + Counter
Audio	MP3 par page en FR et EN	gTTS
Export PPT	Fichier .pptx structuré par IA	python-pptx

Point fort : L'architecture RAG garantit une analyse contextuelle précise — le LLM reçoit simultanément la question et le contenu du PDF.

🌐 Démo : https://lecteurintelligentpdf-ma48ujfhtuhxqprgjjkhqq.streamlit.app/

[1] Mistral AI — console.mistral.ai [2] Streamlit Inc. — streamlit.io [3] PyPDF2 — pypi.org [4] gTTS — pypi.org [5] Herman KANDOLO — github.com